

UNIVERSIDADE FEDERAL DE SÃO CARLOS - CÂMPUS SEDE

**LÓGICA FUZZY: FUNDAMENTOS, APLICAÇÕES E IMPACTOS NA
TECNOLOGIA**

CAROLINA MEGUMI NOGAI¹, YUKI HIROJI OYAMA²

*"A realidade não é algo que pode ser definido com precisão. É algo que deve ser
percebido e interpretado."*

(Jiddu Krishnamurti)

1 Discente do Curso Bacharelado em Ciência da Computação, UFSCar, Câmpus Sede, 834418,
carolinanogai@estudante.ufscar.br.

2 Discente do Curso Bacharelado em Ciência da Computação, UFSCar, Câmpus Sede, 830916,
yuki.oyama@estudante.ufscar.br.

RESUMO

Este trabalho apresenta, de forma detalhada, um estudo aprofundado sobre a Lógica Fuzzy, abordando desde sua contextualização histórica até suas aplicações práticas no mundo contemporâneo. O objetivo principal foi realizar uma análise minuciosa deste método, explorando suas bases teóricas, sua evolução ao longo do tempo e suas principais contribuições para a ciência e tecnologia atuais. A pesquisa adotou uma abordagem rigorosa e didática, com o intuito de explicar este método de entendimento do mundo de maneira acessível e precisa, proporcionando uma visão ampla sobre sua importância. Ao longo da monografia, foram realizadas comparações entre a lógica clássica e a lógica fuzzy, destacando as diferenças fundamentais no tratamento de incertezas e ambiguidades. Também foram discutidas as questões determinísticas que influenciam a compreensão e a modelagem de fenômenos do mundo real, analisando como a lógica fuzzy pode superar as limitações da lógica binária tradicional. Além disso, foram abordados aspectos essenciais, como sua sintaxe e os operadores fundamentais, explicando como esses elementos são aplicados para representar e manipular incertezas. A aplicação da lógica fuzzy em diversos processos foi detalhada, com foco em exemplos de sistemas de controle, inteligência artificial, automação industrial e reconhecimento de padrões, evidenciando sua relevância na organização de sistemas complexos. Finalmente, este trabalho discute suas contribuições para a melhoria de processos e a otimização de sistemas em diversas áreas, demonstrando seu impacto significativo na inovação tecnológica e na resolução de problemas do mundo real.

PALAVRAS-CHAVE: Lógica Fuzzy; lógica clássica; incerteza; ambiguidade; modelagem; aplicações; análise.

INTRODUÇÃO

A Lógica Fuzzy foi desenvolvida pelo matemático e engenheiro iraniano Prof. Dr. Lotfi Zadeh (1921-2017), na Universidade de Berkeley, em 1965, quando publicou pela primeira vez o artigo “Conjuntos Fuzzy” (*Fuzzy Sets*). Zadeh é formado em engenharia elétrica na Universidade de Teerã, continuou seus estudos no Instituto de Tecnologia de Massachusetts, na Universidade de Colúmbia e por fim na Universidade de Berkeley. O objeto de estudo de Zadeh, entende-se, inicialmente, pela etimologia da palavra da “Fuzzy” que vem de difuso, vago, isto é, explicar a ciência e, posteriormente,

o mundo, transpassando a lógica binária, daquilo que é ou não é. Ao analisar os processos históricos de formação do pensamento *logos*, ou seja, da construção da razão para explicar os fenômenos, a lógica clássica opera com definições rígidas e absolutas, enquanto a lógica fuzzy oferece uma forma mais flexível e adaptativa de representar e processar informações, aproximando-se do raciocínio humano. Diferente da lógica booleana, a lógica de Fuzzy é aplicada em cenários ambíguos, quando o computador não consegue chegar a uma conclusão Verdadeira (1) ou Falsa (0). Este método considera todas as ambiguidades de um problema, e diferentes valores em potenciais do que apenas 0 e 1. Ademais, entende-se que a Lógica de Fuzzy permite uma maior fluidez e liquidez ao explicar processos, que são frequentemente complexos. Em outras palavras, assim como a mente e o subconsciente possuem uma natureza fluída, multidimensional e multifacetada, é necessário tomar decisões, com diferentes múltiplos campos de entendimento. Em termos de aplicações, apresenta uma variedade de possibilidades de implementação, tais como o como o FLC (*fuzzy logic controller* - controlador da lógica de fuzzy), um mecanismo usado para regular as operações de um sistema físico, muito utilizado em máquinas de lavar louças, controle de tráfego, etc. Ela também é utilizada como método de tomada de decisões na área de Data Mining, investimentos na bolsa de valores e inteligência artificial.

FUNDAMENTOS DA LÓGICA FUZZY

A Lógica de Fuzzy é definida como uma forma de lógica multivalorada, ou seja, o valor verdade pode assumir qualquer número real entre 0 e 1. Dentro deste espectro, pode-se construir valores intermediários e parciais para determinar processos com graus de dificuldades maiores. Exemplificando esse intervalo, os valores linguísticos “desonesto”, “parcialmente honesto” e “honesto”, podem assumir valores como 0, 0,5 e 1,0, respectivamente. Dessa forma, permite trabalhar as nuances dentro do intervalo, que neste caso, é constituído valores da linguagem natural. Além disso, assim como na lógica clássica, é necessário um conjunto de proposições no formato “se ..., então ...” para chegar a uma conclusão sobre o problema. Essas proposições também podem conter operadores como o “E” e “OU”, representando uma intersecção e união entre as proposições variáveis. A lógica de Fuzzy é um sistema composto por três blocos elementares: fuzzificação, tomada de decisão e defuzzificação. Esses processos são lineares e dependentes um do outro, na etapa de tomada de decisão não é possível chegar a uma conclusão apenas com os inputs básicos recebidos, por isso ele passa pelo

processo de fuzzificação e mais tarde pelo processo de defuzzificação para que o output seja um valor quantificável.

No processo de fuzzificação, os *inputs* — valores bem definidos quantificáveis e sem termos intermediários, conhecidos como *crisps* — são divididos de acordo com o grau de pertencimento de cada elemento em uma função de pertinência. Essas funções tomam valores entre 0 e 1 e são definidas de forma manual. Para melhor compreensão, é possível tomar como exemplo o processo de fuzzificação da seguinte sentença: “A comida é boa?”, na lógica clássica a resposta seria apenas ‘Sim’ ou ‘Não’, já no processo de fuzzificação nossos *inputs* são transformados em diversas funções de pertinência como listado abaixo:

A comida é ruim: 0 a 4 pontos

A comida é moderada: 4 a 6 pontos

A comida é boa: Acima de 7 pontos




Figura 1 - Gráfico adaptado com funções de pertinência

As funções de pertinência são definidas por dois parâmetros. No eixo x, encontram-se os inputs e no eixo y o grau de pertinência, ou seja, para cada valor do input há um grau de pertinência atribuído a ele na função. Vamos tomar como exemplo a função *low*, no intervalo de 0 a 3 pontos o grau de pertinência é 1, ou seja 100%, agora quando observado um valor 3.5 o grau de pertinência é de aproximadamente 45%. Além disso, com base no gráfico e seus graus de pertinência podemos definir um corte α que divide o gráfico em núcleo — topo do gráfico, valores que assumem um grau de pertinência 100% — e suporte — base do gráfico, com todos os valores possíveis para a função e graus de pertinência variando (Figura 2).

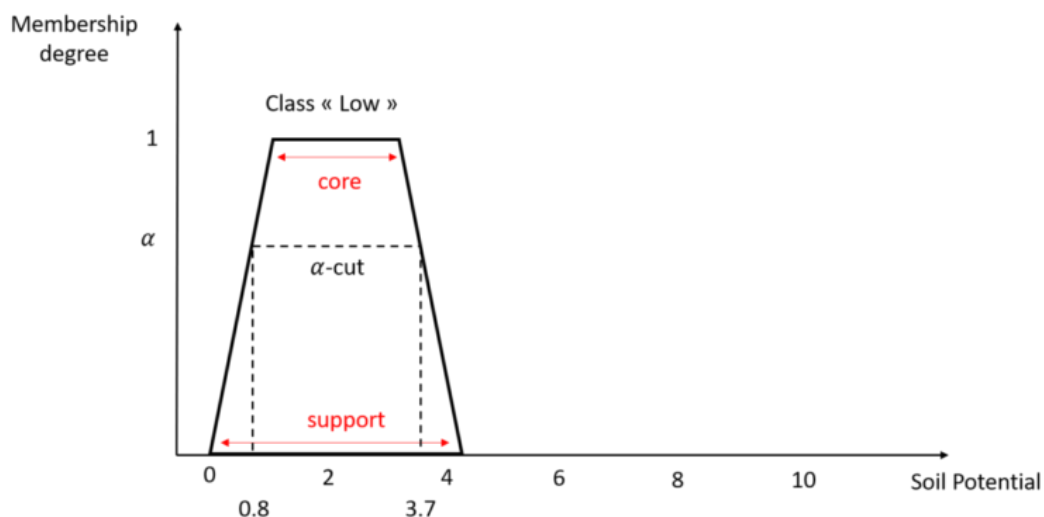


Figura 2 - Gráfico com nomenclaturas

Conforme mencionado anteriormente, as funções de pertinência podem assumir valores entre 0 e 1, mas sua representação gráfica não é única. Elas podem ser expressas de diversas formas, desde que mantenham coerência com a variável que descrevem. É observado pela figura a seguir:

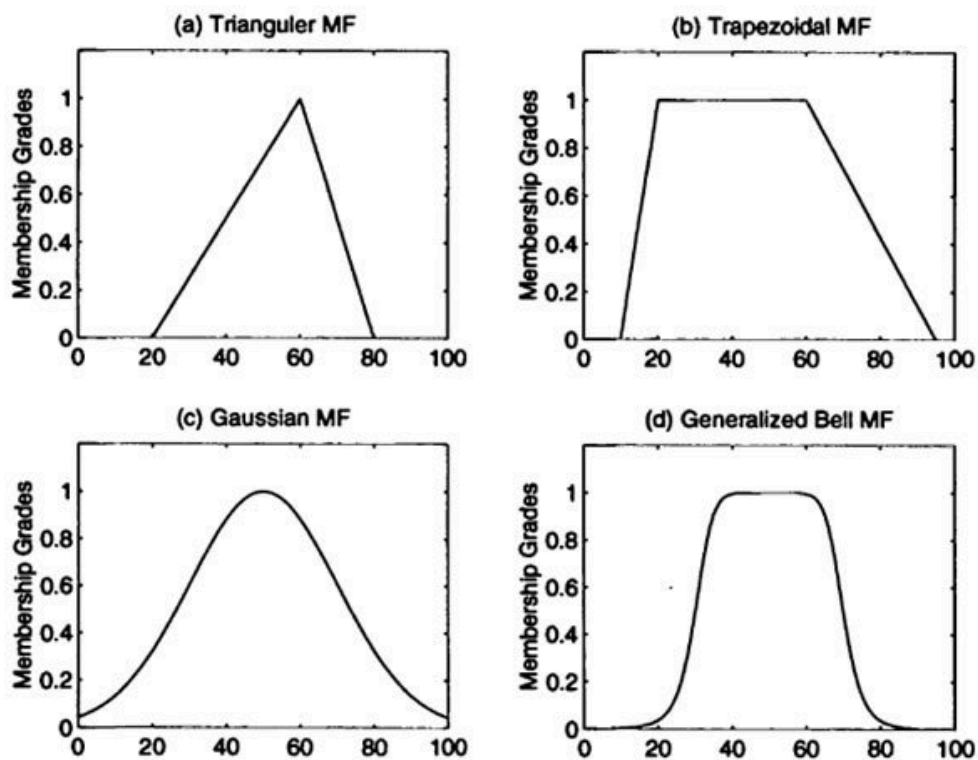


Figura 3 - Gráficos com diferentes tipos de funções de pertinência

Ao analisar a figura 3 compreende-se que o item (a) é uma representação com formato triangular (*Triangular Membership Function (MF)*), o (b) é trapezoidal (*Trapezoidal Membership Function (MF)*), semelhante à triangular, com o topo achatado, já o (c) é baseada na distribuição Gaussiana (*Gaussian Membership Function (MF)*), com formato suave e simétrico e (d) sendo a Sino Generalizada (*Generalized Bell Membership Function (MF)*), que é mais flexível do que a Gaussiana, pois permite ajustar a inclinação e a curvatura das extremidades.

Agora que foram apresentadas as diferentes funções de pertinência, torna-se fundamental compreender como elas são implementadas em sistemas fuzzy. Para isso, é necessário explorar a sintaxe utilizada na lógica fuzzy. Os predicados fuzzy incluem, por exemplo, termos como longo, breve, rápido, pesado e expressões comparativas como muito maior do que. Além disso, esses predicados podem ser modificados para representar valores intermediários por meio de advérbios, como mais, menos, completamente e infinitamente, permitindo um refinamento na descrição das variáveis linguísticas. Os quantificadores, por sua vez, são divididos em quantificadores gerais, como todos, e quantificadores existenciais, como pelo menos um, desempenhando um papel essencial na formulação de regras fuzzy. Já os operadores, eles diferem dos operadores booleanos, sendo que AND-FUZZY pode ser o mínimo entre os valores ($\min(x,y)$) suavizando a transição, OR-FUZZY pode ser o máximo ($\max(x,y)$), permitindo valores intermediários e NOT-FUZZ, calculado como $1-x$, refletindo o grau de negação. Veja-se na figura a seguir:

Boolean	Fuzzy
AND(x,y)	MIN(x, y)
OR(x,y)	MAX(x,y)
NOT(x)	1-X

Figura 4 - Tabela comparativa de operadores booleanos e operadores fuzzy

Seguindo o exemplo da avaliação de uma comida, uma segunda variável pode ser adicionada na etapa de tomada de decisões. Por exemplo, se é necessário avaliar um restaurante, a comida não é o único critério, o serviço prestado também pode ser levado em consideração. Para isso, o gráfico de pertinência do serviço e avaliação do

restaurante também passam pelo processo de fuzzificação. Na figura 5, há o gráfico de um serviço avaliado em bom ou ruim, já na figura 6, o gráfico da avaliação de um restaurante.




Figura 4 - Funções de pertinência do serviço

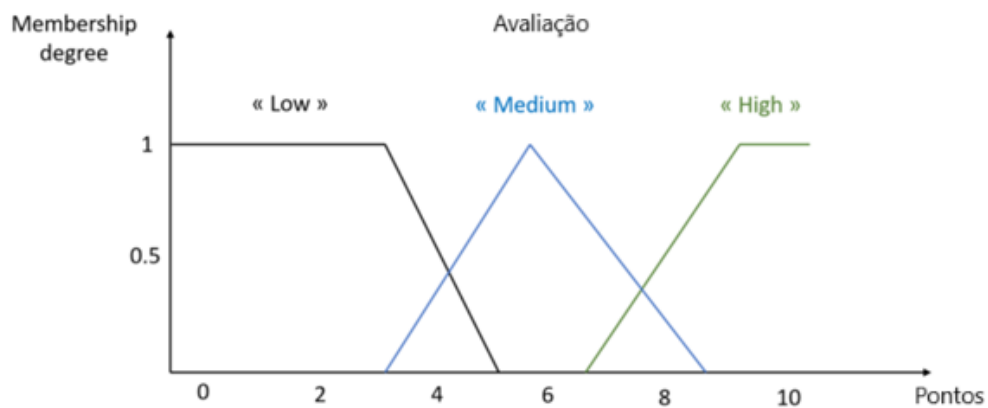


Figura 5 - Funções de pertinência da avaliação

Com base nessas novas funções é possível definir regras para a tomada de decisão. Essas regras não precisam necessariamente usar todas as variáveis ou existir uma regra para cada caso. Continuando no exemplo é possível atribuir as seguintes regras:

Se a comida é boa ou o serviço é bom, a avaliação é boa.

Se a comida é moderada, então a avaliação é satisfatória.

Se a comida é ruim e o serviço é ruim, então a avaliação é péssima.

Para cada uma das regras definidas há uma saída com grau de pertinência corresponde ao gráfico da avaliação, esse grau de pertinência depende do operador escolhido como explicado na tabela da figura 4. Abaixo é possível visualizar os gráficos das regras definidas.




Figura 6 - Regra 1



Figura 7 - Regra 2




Figura 8 - Regra 3

Esse processo resulta em diversos conjuntos fuzzy, que precisam ser traduzidos novamente para um conjunto de críps correspondente à avaliação final do restaurante. Assim, o processo de defuzzificação é essencial. Existem vários métodos que podem ser utilizados nessa etapa, mas dois deles são os principais:

O primeiro é o método da média máxima (MM), no qual o output é calculado como a média dos valores das abscissas para cada máximo do grau de pertinência. Na Figura 9, observa-se que a máxima pertinência é de 0,8, e os valores das abscissas correspondentes ao máximo pertencem ao intervalo [5-6,5]. O valor final do output é obtido calculando a média desse intervalo, ou seja, $(5 + 6,5)/2 = 5,75$ t/ha. Esse método é considerado simples e eficiente, porém, pode ser visto como uma abordagem rígida, pois apenas considera os pontos de máxima pertinência, desconsiderando o restante da distribuição fuzzy.

O segundo método amplamente utilizado é o método do centro de gravidade (COG). Esse método calcula o output como o valor da abscissa correspondente ao centro de gravidade da área sob a curva fuzzy resultante. Na Figura 9, essa área está representada pela curva vermelha, e o valor resultante da defuzzificação pelo método COG está em torno de 6,2 t/ha. Esse método leva em consideração toda a distribuição fuzzy, tornando-se uma abordagem mais flexível e representativa. Entretanto, devido ao cálculo do centro de gravidade, sua implementação é mais complexa e computacionalmente mais custosa.

Assim como acontece com os operadores fuzzy, a escolha do método de defuzzificação impacta diretamente no resultado final do sistema de inferência fuzzy. O método da média máxima pode ser adequado para situações onde a simplicidade e a rapidez são prioridades, enquanto o método do centro de gravidade oferece uma interpretação mais refinada e precisa dos conjuntos fuzzy.

A decisão sobre qual método utilizar deve ser baseada nas necessidades específicas da aplicação, no nível de precisão desejado e nos recursos computacionais disponíveis. Em muitos sistemas de inferência fuzzy, o método COG é o mais empregado devido à sua maior representatividade dos dados de entrada. No entanto, quando se busca uma solução mais rápida e menos onerosa em termos computacionais, o método da média máxima pode ser uma escolha viável.

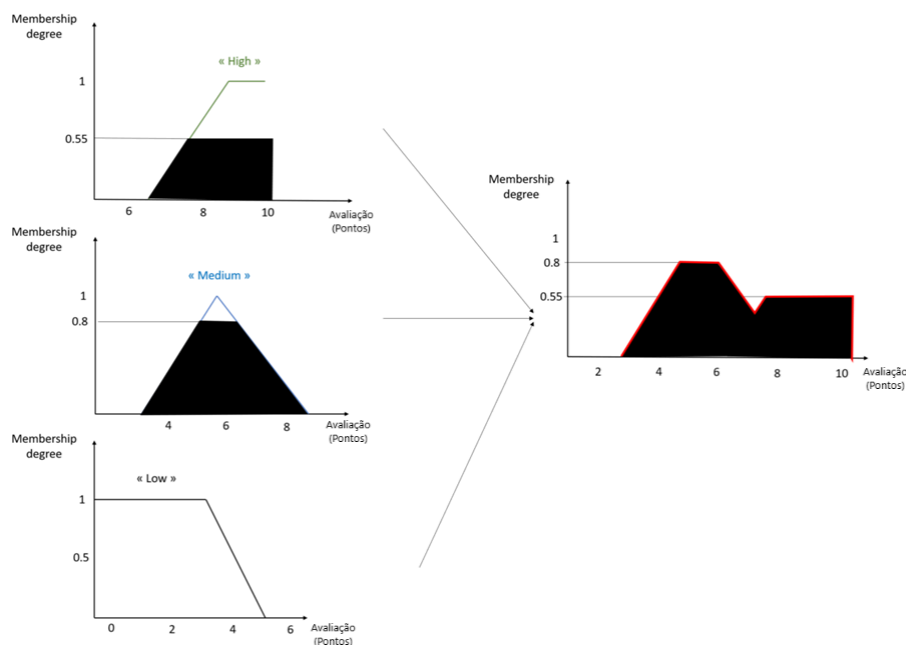


Figura 9 - Resultado das regras

Em termos comparativos, a lógica clássica, também conhecida como lógica aristotélica, é baseada no princípio do terceiro excluído, onde uma proposição só pode assumir um dos dois valores: verdadeiro (1) ou falso (0). Esse modelo binário foi a base do pensamento lógico por séculos e continua sendo amplamente utilizado, especialmente na computação digital e em sistemas determinísticos. Por outro lado, ela surge como uma extensão da lógica clássica, oferecendo mais flexibilidade para lidar com incertezas e imprecisões, sem contrariar a estrutura formal do modelo tradicional. Em vez de restringir-se a valores binários, a lógica fuzzy permite graus de verdade, possibilitando uma transição mais fluida entre os extremos absolutos de verdadeiro e falso. Isso torna seu funcionamento mais próximo do raciocínio humano e dos fenômenos do mundo real, onde muitas situações não podem ser definidas de forma estritamente binária. Diferente da lógica multivalorada, onde uma afirmação pode ser verdadeira, falsa ou ambígua, mas nunca parcialmente verdadeira ou falsa, a lógica fuzzy permite que cada afirmação tenha um grau de pertencimento entre 0 e 1. Isso significa que um conceito pode ser parcialmente verdadeiro e parcialmente falso ao mesmo tempo, dependendo do contexto. O estudo de Lafti preserva a base estrutural da lógica aristotélica, apenas estendendo seus princípios. Aristóteles defendia que o valor de uma proposição era sempre verdadeiro ou falso, e que a verdade da sentença completa dependia da verdade de suas partes. A lógica fuzzy amplia essa visão ao permitir que cada cláusula tenha um valor intermediário, refletindo a complexidade e a subjetividade do mundo real. Dessa forma, ela não substitui a lógica clássica, mas a complementa, proporcionando um modelo mais adaptável e eficiente para lidar com situações onde a incerteza e a ambiguidade estão presentes. Isso explica seu amplo uso em inteligência artificial, controle de sistemas e automação, onde decisões precisam ser tomadas com base em informações parciais ou imprecisas.

3. APLICAÇÕES EM INTELIGÊNCIA ARTIFICIAL

A lógica fuzzy é amplamente aplicada em diversas áreas, especialmente na Inteligência Artificial (IA), devido à sua capacidade de lidar com incertezas e variabilidade nas informações. Ela permite a modelagem de problemas em que as variáveis não são nítidas ou não podem ser representadas por valores exatos. Assim, pode-se exemplificar em:

Análise de árvores de decisão que é utilizada para construir a lógica fuzzy em sua forma mais rudimentar. Como consequência, ela serve como base para algoritmos de IA desenvolvidos com conclusões baseadas em regras.

Sistemas de aprendizado de máquina, onde a lógica fuzzy e o aprendizado de máquina são, por vezes, utilizados conjuntamente. No entanto, apesar de suas interseções, eles não são idênticos. Enquanto o aprendizado de máquina ajusta algoritmos para resolver problemas complexos de forma iterativa, a lógica fuzzy trabalha com conjuntos de regras para lidar com dados imprecisos, ainda exigindo que humanos escrevam os algoritmos.

Mineração de dados, que permite encontrar correlações significativas em grandes conjuntos de dados. A lógica fuzzy pode ser aplicada em dados imprecisos para alcançar conclusões lógicas, sendo um método eficaz para identificar padrões e correlações em medições imperfeitas.

Aplicações em inteligência artificial, como o sistema Watson da IBM, um dos sistemas de IA mais populares que utilizam lógica fuzzy e semântica fuzzy para processar informações complexas e gerar inteligência aplicada a setores como serviços financeiros.

4. CONSIDERAÇÕES FINAIS

Ao longo desta pesquisa foi possível perceber a ferramenta poderosa que é a lógica fuzzy, que é a sua capacidade de lidar com incertezas e imprecisões, proporcionando soluções flexíveis e mais próximas da realidade humana. Ao mencionar as vantagens, pode-se citar a sua habilidade em lidar com diferentes tipos de entrada, incluindo dados imprecisos, distorcidos ou ruidosos, e reflete o raciocínio humano, oferecendo soluções eficazes para problemas complexos. Com base em conceitos matemáticos, como a teoria dos conjuntos, permite a implementação de algoritmos com poucos dados e baixo consumo de memória. Além disso, o sistema é facilmente ajustável para otimizar seu desempenho e pode funcionar mesmo na ausência de sensores de *feedback*. Em comparação com a lógica clássica, a lógica fuzzy se destaca por sua maior capacidade de representar desafios do mundo real de maneira mais flexível e precisa. No entanto, percebem-se algumas desvantagens da lógica fuzzy que incluem a necessidade de validação e verificação extensiva dos algoritmos, além da dependência de habilidades e compreensão humanas para o controle. Esses sistemas, a

menos que configurados adequadamente, não conseguem integrar aprendizado de máquina ou redes neurais. A definição precisa de conjuntos fuzzy e funções de pertinência exige tempo e esforço consideráveis. A lógica fuzzy pode não ser sempre precisa, com resultados dependentes de preconceitos, o que pode limitar sua aceitação. Além disso, a falta de uma estratégia sistemática para resolver problemas específicos resulta em soluções ambíguas. Após analisar as vantagens e desvantagens da lógica fuzzy, é essencial destacar um aspecto importante: a relação dessa abordagem com a teoria das probabilidades. Embora ambas lidam com incertezas, elas são baseadas em conceitos distintos e, por isso, são aplicadas de maneiras diferentes. A lógica fuzzy, ao lidar com graus de verdade e ambiguidade, busca capturar a imprecisão de conceitos que não são nem totalmente verdadeiros nem completamente falsos. Em contraste, a teoria das probabilidades lida com eventos claramente definidos e quantifica o grau de certeza sobre sua ocorrência. Dessa forma, ao aprofundar o estudo da lógica fuzzy, torna-se crucial compreender as diferenças entre pertinência e probabilidade, dois conceitos-chave que ilustram as distinções entre esses dois sistemas de raciocínio. A seguir, exploraremos como cada um desses conceitos se aplica a diferentes tipos de incerteza e como eles se complementam ou se substituem dependendo da situação. A pertinência, no contexto da lógica fuzzy, refere-se ao grau em que um elemento pertence a um conjunto fuzzy. Ao contrário da lógica clássica, que adota uma associação binária e absoluta, a pertinência é expressa como um valor contínuo entre 0 e 1, indicando a intensidade com que um elemento pertence a um conjunto específico. Por exemplo, em um conjunto fuzzy para "temperaturas quentes", a pertinência de 30°C poderia ser 0.8, sugerindo que essa temperatura é considerada quente, mas não de forma absoluta, refletindo a imprecisão inerente a esse conceito. Por outro lado, a probabilidade é um conceito central na teoria das probabilidades, utilizado para descrever a chance de ocorrência de um evento específico, também expresso como um valor entre 0 e 1. A probabilidade é aplicada a eventos bem definidos, que são, em última instância, verdadeiros ou falsos. Ela quantifica o grau de certeza sobre a ocorrência de um evento com base em informações anteriores ou dados empíricos. Diferentemente da pertinência, que lida com graus de verdade imprecisos, a probabilidade trata de eventos claramente definidos que podem ou não ocorrer. Agora, considerando o contexto de outras lógicas, podemos analisar como a lógica fuzzy se diferencia delas:

Lógica Inferencial: Na lógica inferencial, busca-se deduzir conclusões a partir de premissas de maneira formal e estruturada. A lógica fuzzy se diferencia ao permitir que a conclusão também envolve valores parciais, representados por graus de pertinência, ao invés de simplesmente concluir se algo é verdade ou falso;

Lógica Simbólica: A lógica simbólica utiliza símbolos e regras formais para representar proposições de maneira clara e objetiva. A lógica fuzzy, embora também envolva regras formais, lida com proposições que podem ser parcialmente verdadeiras, permitindo uma abordagem mais flexível e adaptável à imprecisão, contrastando com a rigidez dos valores binários da lógica simbólica;

Lógica Social: Em relação à lógica social, como proposta por Durkheim, que aborda os estados transcendental completo, limitado e gnóstico do ser humano e da sociedade, podemos ver que a lógica fuzzy se aproxima dessa visão ao permitir que os estados da realidade sejam descritos não de forma absoluta, mas como uma gama de possibilidades, ou seja, com diferentes graus de pertinência. Assim, a lógica fuzzy é mais adequada para modelar a complexidade e a variabilidade das relações sociais, que não podem ser totalmente descritas por valores binários;

Lógica Empírica: a lógica empírica, que lida com as emoções humanas e com dados subjetivos, pode ser comparada com a lógica fuzzy, pois ambas lidam com incertezas e variações. Em um contexto emocional, as respostas não são “sim” ou “não”, mas podem ser vistas em uma escala de intensidades ou graus. A lógica fuzzy, assim como a lógica empírica, permite descrever essas nuances e complexidades que fogem à definição rígida da lógica clássica. A lógica fuzzy é interessante porque vai além do binário 0 e 1, permitindo representar valores intermediários. Isso torna a lógica extremamente versátil, aplicável em diversas áreas, como inteligência artificial e controle de sistemas. Ela também é capaz de lidar com incertezas e situações difusas, onde as informações não são precisas, como no caso de afirmações vagas. Assim, a lógica fuzzy oferece uma abordagem mais flexível e realista para modelar o mundo, representando melhor a complexidade e a variabilidade das situações.

Os autores deste trabalho, Carolina e Yuki, encontraram dificuldades em representar os gráficos de forma clara e didática, já que a lógica fuzzy envolve valores contínuos, o que exige uma visualização cuidadosa para facilitar a compreensão. Comparar a lógica fuzzy com outras lógicas, como a booleana, também exigiu cuidado, para destacar as vantagens da fuzzy em lidar com incertezas e valores intermediários.

AGRADECIMENTOS

Agradecemos à Universidade Federal de São Carlos - Câmpus Sede e ao Prof. Dr. Alexandre Luis Magalhães Levada, ministrante da disciplina de Lógica Matemática, pelo apoio e orientação essenciais para a realização deste trabalho.

REFERÊNCIAS

CANAL XYZ. Introdução à Lógica Fuzzy. *YouTube*, 29 jan. 2025. Disponível em: <https://youtu.be/pbe9hZcGIiU?feature=shared>. Acesso em: 29 jan. 2025.

ASPEXIT. Fuzzy Logic or the Extension of Classical Logic. *Aspexit*. Disponível em: <https://www.aspexit.com/fuzzy-logic-or-the-extension-of-classical-logic/>. Acesso em: 29 jan. 2025.

SHEIKH, Mohammad Ali et al. Fuzzy Logic and Its Applications. *International Journal of Numerical Analysis and Modeling*, v. 11, n. 4, p. 576-589, 2020. Disponível em: https://ijnaa.semnan.ac.ir/article_8836_7651b1c8ecf95b40efac09fbf1bdc7c8.pdf. Acesso em: 29 jan. 2025.

SPICEWORKS. What is Fuzzy Logic? *Spiceworks*. Disponível em: <https://www.spiceworks.com/tech/devops/articles/fuzzy-logic/>. Acesso em: 29 jan. 2025.